



USFQ – Workshop Inteligencia Artificial

Asignatura: Inteligencia Artificial

Grupo #1

Integrantes:

- Evelyn Bermeo
- Jairo Cabrera
- Javier Cuzco
- Nicolás Carrión

Modelos de lenguaje y algoritmos de búsqueda: análisis, comparaciones y diferencias

Introducción

La evolución reciente de la inteligencia artificial ha estado marcada por el surgimiento de los modelos de lenguaje de gran escala (LLM, Large Language Models), especialmente aquellos basados en la arquitectura Transformer. Modelos como GPT, Gemini o LLaMA han demostrado capacidades sorprendentes para comprender lenguaje natural, generar texto coherente, resolver problemas complejos e incluso asistir en tareas de razonamiento. Sin embargo, el crecimiento de estas capacidades ha generado un debate importante dentro de la comunidad científica: ¿funcionan realmente los LLM como algoritmos de búsqueda?

Tradicionalmente, los algoritmos de búsqueda han sido utilizados en inteligencia artificial para explorar espacios de estados y encontrar soluciones óptimas o aproximadas a problemas específicos. Algoritmos como Breadth-First Search (BFS), Depth-First Search (DFS), A*, búsqueda heurística o algoritmos evolutivos operan siguiendo reglas explícitas de exploración y evaluación. Por otro lado, los LLM aprenden patrones estadísticos a partir de enormes volúmenes de datos utilizando redes neuronales profundas basadas en atención.

Aunque ambos enfoques buscan resolver problemas y producir respuestas útiles, existen diferencias fundamentales entre los mecanismos internos de los algoritmos de búsqueda y los modelos de lenguaje. Este ensayo analiza el funcionamiento interno de los modelos

Transformer, estudia su relación con los algoritmos de búsqueda y evalúa críticamente si los LLM pueden considerarse realmente sistemas de búsqueda o si representan un paradigma distinto dentro de la inteligencia artificial.

Arquitectura Transformer y funcionamiento de los LLM

Los modelos de lenguaje modernos se fundamentan principalmente en la arquitectura Transformer, presentada por Vaswani et al. en 2017. Esta arquitectura revolucionó el procesamiento de lenguaje natural debido a su capacidad para manejar dependencias largas dentro de una secuencia mediante el mecanismo de atención (“attention mechanism”).

El componente central del Transformer es la autoatención (self-attention), que permite que cada palabra de una secuencia evalúe la importancia de las demás palabras al momento de generar una representación contextual. Gracias a esto, los modelos pueden comprender relaciones semánticas complejas y producir respuestas más coherentes que arquitecturas anteriores como las redes recurrentes (RNN) o LSTM.

Matemáticamente, la atención puede representarse mediante la siguiente ecuación:

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{Q K^T}{\sqrt{d_k}}\right) V$$

Donde:

- Q representa las consultas (queries),
- K las claves (keys),
- V los valores (values),
- y d_k la dimensión de las claves.

Este mecanismo permite que el modelo identifique qué partes de la información son más relevantes durante el proceso de generación textual.

Los LLM son entrenados mediante aprendizaje auto-supervisado sobre enormes cantidades de texto. Durante el entrenamiento, el modelo aprende a predecir la siguiente palabra en una secuencia. Aunque este objetivo parece simple, la escala masiva de datos y parámetros permite que emerjan capacidades complejas de razonamiento, síntesis y generación.

Sin embargo, estos modelos también presentan limitaciones importantes, como alucinaciones, conocimiento desactualizado y falta de interpretabilidad. Precisamente para enfrentar estas limitaciones surgieron enfoques como Retrieval-Augmented Generation (RAG), que integran mecanismos de recuperación de información externa con modelos generativos.

Algoritmos de búsqueda en inteligencia artificial

Los algoritmos de búsqueda constituyen uno de los pilares clásicos de la inteligencia artificial. Su objetivo consiste en explorar un conjunto de posibles estados o soluciones para encontrar aquella que cumpla determinados criterios.

Por ejemplo:

- BFS explora todos los nodos nivel por nivel.
- DFS profundiza primero en una rama antes de retroceder.
- A* utiliza funciones heurísticas para encontrar caminos óptimos.
- Los algoritmos evolutivos exploran soluciones mediante selección y mutación.

En términos generales, un algoritmo de búsqueda posee:

1. Un espacio de estados.
2. Reglas de transición.
3. Una función objetivo o heurística.
4. Un criterio de parada.

La diferencia principal respecto a los LLM es que los algoritmos de búsqueda trabajan mediante exploración explícita de posibilidades, mientras que los modelos Transformer generan respuestas a partir de representaciones aprendidas estadísticamente.

No obstante, investigaciones recientes muestran que ciertos comportamientos de los LLM pueden asemejarse parcialmente a procesos de búsqueda implícita. Algunos estudios sugieren que durante la generación textual el modelo evalúa múltiples posibles continuaciones y selecciona la más probable mediante distribuciones probabilísticas internas.

¿Funcionan los LLM como algoritmos de búsqueda?

La pregunta central de este ensayo es si los modelos de lenguaje pueden considerarse algoritmos de búsqueda. La respuesta más adecuada es que los LLM no son algoritmos de búsqueda en el sentido clásico, aunque sí incorporan ciertos mecanismos relacionados con exploración y selección probabilística.

Los algoritmos tradicionales de búsqueda operan sobre espacios explícitos y siguen procedimientos definidos para recorrerlos. En cambio, los LLM trabajan sobre espacios latentes aprendidos durante el entrenamiento. Es decir, el modelo no “busca” directamente documentos o soluciones paso a paso, sino que predice la salida más probable utilizando patrones estadísticos almacenados en sus parámetros.

Sin embargo, algunas técnicas modernas han acercado ambos paradigmas. Un ejemplo importante es RAG (Retrieval-Augmented Generation), donde el modelo combina generación de lenguaje con recuperación de información externa. Según Gao et al. (2024), RAG busca mejorar precisión, actualidad y trazabilidad del conocimiento mediante recuperación dinámica de información.

El estudio sobre avances en RAG explica que estos sistemas utilizan técnicas de recuperación, indexación y reranking similares a motores de búsqueda modernos.

Además, incorporan optimización de consultas, embeddings semánticos y recuperación iterativa para refinar respuestas complejas.

En este contexto, los LLM dejan de depender únicamente de su memoria paramétrica y comienzan a utilizar mecanismos de búsqueda reales sobre bases de datos externas. Por tanto, puede afirmarse que:

- Un LLM puro no funciona exactamente como un algoritmo de búsqueda.
- Un sistema híbrido como RAG sí integra componentes claros de búsqueda y recuperación.

Esto representa una convergencia importante entre inteligencia artificial generativa y recuperación de información.

Relación entre búsqueda y razonamiento en los LLM

Otra área relevante es el uso de los LLM para resolver problemas de optimización y búsqueda compleja. El documento “LM-Searcher” propone utilizar modelos de lenguaje para realizar búsqueda de arquitecturas neuronales (NAS, Neural Architecture Search).

En esta investigación, las arquitecturas neuronales son codificadas mediante representaciones numéricas denominadas “NCode”, permitiendo que el modelo aprenda relaciones entre configuraciones y desempeño. El sistema transforma el problema de búsqueda en una tarea de clasificación y selección de candidatos.

Esto demuestra que los LLM pueden participar en procesos de optimización y búsqueda cuando son diseñados específicamente para ello. Sin embargo, el mecanismo continúa siendo diferente a la búsqueda clásica:

- El algoritmo de búsqueda tradicional explora explícitamente opciones.
- El LLM aprende patrones históricos y predice probabilidades.

En otras palabras, los LLM no reemplazan completamente a los algoritmos de búsqueda, sino que pueden complementarlos mediante razonamiento estadístico y aprendizaje profundo.

Diferencias fundamentales entre LLM y algoritmos de búsqueda

Existen varias diferencias importantes entre ambos enfoques:

Aspecto	Algoritmos de búsqueda	Modelos LLM
Método principal	Exploración explícita	Predicción probabilística
Representación	Espacios de estados definidos	Espacios latentes aprendidos
Interpretabilidad	Alta	Baja

Necesidad de entrenamiento	No necesariamente	Sí
Adaptabilidad	Limitada	Alta
Manejo de lenguaje natural	Limitado	Muy avanzado
Actualización de conocimiento	Manual	Requiere reentrenamiento o RAG

A pesar de estas diferencias, los sistemas híbridos actuales están integrando ambos paradigmas. Los modelos generativos modernos utilizan recuperación de información, búsqueda semántica y razonamiento iterativo para mejorar sus capacidades.

Desafíos y limitaciones

Aunque los LLM han mostrado capacidades impresionantes, todavía enfrentan importantes desafíos:

- Alucinaciones y generación de información incorrecta.
- Dependencia de datos de entrenamiento.
- Costos computacionales extremadamente altos.
- Dificultad de interpretación interna.
- Riesgos éticos y sesgos.

Los sistemas RAG ayudan parcialmente a resolver algunos de estos problemas al incorporar recuperación dinámica de información externa. No obstante, todavía existen dificultades relacionadas con escalabilidad, calidad de recuperación y coherencia contextual.

Conclusiones

Los modelos de lenguaje basados en arquitectura Transformer representan uno de los mayores avances recientes en inteligencia artificial. Su capacidad para comprender y generar lenguaje natural ha transformado múltiples áreas, desde asistentes virtuales hasta investigación científica.

Sin embargo, los LLM no funcionan como algoritmos de búsqueda tradicionales. Mientras los algoritmos de búsqueda exploran explícitamente espacios de soluciones mediante heurísticas y reglas formales, los LLM generan respuestas utilizando patrones probabilísticos aprendidos en enormes volúmenes de datos.

Aun así, la integración de técnicas de recuperación de información mediante enfoques como RAG demuestra una convergencia progresiva entre ambos paradigmas. Los sistemas modernos combinan generación lingüística, recuperación semántica y razonamiento probabilístico para producir respuestas más precisas y contextualizadas.

Además, investigaciones recientes muestran que los LLM pueden apoyar procesos de optimización y búsqueda compleja, aunque desde una perspectiva distinta a la búsqueda

clásica. Por ello, el futuro de la inteligencia artificial probablemente no dependerá exclusivamente de modelos generativos o algoritmos de búsqueda por separado, sino de sistemas híbridos capaces de integrar razonamiento, recuperación y generación de manera eficiente.

Referencias:

Ahmed, S. (2025). *Advancements in RAG: A comprehensive survey of techniques and applications*. Medium. <https://medium.com/@sahin.samia/advancements-in-rag-a-comprehensive-survey-of-techniques-and-applications-b6160b035199>

Gao, Y., Xiong, Y., Gao, X., Jia, K., Pan, J., Bi, Y., Dai, Y., Sun, J., Wang, M., & Wang, H. (2024). *Retrieval-Augmented Generation for Large Language Models: A Survey*. arXiv. <https://doi.org/10.48550/arXiv.2312.10997>

Hu, Y., Liu, J., Wang, K., Zheng, J., Shi, W., Zhang, M., Dou, Q., Liu, R., Zhou, A., & Li, H. (2025). *LM-Searcher: Cross-domain Neural Architecture Search with LLMs via Unified Numerical Encoding*. arXiv. <https://arxiv.org/abs/2509.05657>

Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, Ł., & Polosukhin, I. (2017). *Attention is All You Need*. Advances in Neural Information Processing Systems, 30.