

PROYECTO FINAL DE INTELIGENCIA ARTIFICIAL

Resolucion del TSP mediante Algoritmos Geneticos

Informe profesional del proyecto

Grupo 5

Nancy Altamirano

Gustavo Berru

Raquel Pacheco

Kevin Viteri

Ciencia de Datos

Mayo de 2026

Indice del informe

1. Resumen ejecutivo
2. Objetivo y enfoque metodologico
3. a) Representacion de individuos como permutaciones validas
4. b) Operadores geneticos seleccionados y justificacion
5. c) Analisis de la evolucion del fitness
6. d) Medicion y analisis de diversidad poblacional
7. e) Evaluacion de la calidad de las soluciones
8. f) Analisis experimental de parametros
9. Conclusiones tecnicas
10. Resumen de participacion del Grupo 5
11. Referencias de apoyo

Resumen ejecutivo

Este proyecto resuelve el Problema del Viajante de Comercio (TSP) mediante un Algoritmo Genetico Generacional Elitista. El TSP exige encontrar un recorrido cerrado que visite cada ciudad exactamente una vez y retorne al origen minimizando la distancia total. Por esa razon, la solucion no se represento como cadena binaria, sino como una permutacion de indices de ciudades. Esta decision evita, desde el diseno del cromosoma, rutas con ciudades repetidas o faltantes.

Se procesaron 10 datasets con entre 80 y 88 ciudades. El algoritmo uso seleccion por torneo, cruce OX, mutacion por inversion, elitismo de dos individuos y mejora final 2-opt. Todas las soluciones finales fueron validas (True) y no se generaron hijos invalidos durante la ejecucion. En promedio, el AG elitista + 2-opt redujo la distancia frente a Nearest Neighbor en 7.83%. Frente a Nearest Neighbor con 2-opt, el promedio fue -0.39%, lo que muestra que el AG fue competitivo incluso contra una heuristica ya refinada.

Idea central para la defensa: El algoritmo elegido es elitista porque conserva las mejores rutas entre generaciones; OX no es otro algoritmo, sino el operador de crossover que permite combinar rutas sin romper la estructura de permutacion del TSP.

Objetivo y enfoque metodologico

El objetivo del ejercicio es implementar y analizar una solucion evolutiva para el TSP cumpliendo seis literales: representacion valida, operadores geneticos adecuados, evolucion del fitness, diversidad poblacional, comparacion con una heuristica y analisis experimental de parametros. El enfoque utilizado fue experimental y reproducible: los datasets se leyeron desde archivos CSV con columnas city, x e y; luego se calculo una matriz de distancias euclidianas y se ejecuto el algoritmo con semilla fija para permitir replicacion.

Configuracion base usada en la ejecucion principal:

Elemento	Valor
Representacion	Permutacion de ciudades
Fitness	1 / distancia_total
Tamano poblacional	100
Generaciones	250
Seleccion	Torneo k = 3
Crossover	OX, probabilidad 0.90
Mutacion	Inversion, probabilidad 0.15
Elitismo	2 mejores individuos preservados
Comparacion	Nearest Neighbor y Nearest Neighbor + 2-opt
Mejora local final	2-opt aplicado a la mejor ruta del AG

Datasets trabajados

Dataset	Numero de ciudades
cities_100_101112	85
cities_100_123	82
cities_100_131415	88
cities_100_161718	80
cities_100_192021	80
cities_100_222324	82
cities_100_252627	84
cities_100_282930	83
cities_100_456	84
cities_100_789	80

a) Representacion de cada individuo como una permutacion valida de ciudades

Cada individuo se represento como un vector ordenado de indices de ciudades. Si existen n ciudades, un cromosoma valido contiene exactamente los valores de 0 a $n-1$, sin repetir ninguno. El orden de los genes define el orden de visita. La ruta se considera cerrada porque, despues de visitar la ultima ciudad, el algoritmo suma la distancia de retorno hacia la primera ciudad.

Ejemplo conceptual: [4, 1, 7, 0, 3, 2, 6, 5] significa que el viajante inicia en la ciudad 4, continua por la 1, luego por la 7, y asi sucesivamente, hasta volver a la ciudad 4. Esta representacion es la adecuada para el TSP porque el problema no busca activar o desactivar ciudades, sino ordenar todas las ciudades disponibles.

Garantia de validez solicitada en el literal:

Fase	Mecanismo aplicado	Justificacion de validez
Inicializacion	Se genera cada individuo con una permutacion aleatoria de $0..n-1$. Tambien se incluye una ruta semilla Nearest Neighbor, que igualmente contiene todas las ciudades una sola vez.	Sin repetidas y sin faltantes desde la primera poblacion.
Crossover OX	Copia un segmento del padre 1 y completa con las ciudades del padre 2 que aun no estan en el hijo.	No duplica ciudades porque solo inserta genes no usados; no omite ciudades porque completa todas las posiciones.
Mutacion por inversion	Invierte el orden de un segmento interno de la misma ruta.	No cambia el conjunto de ciudades; solo cambia su posicion.
Validacion en codigo	Se usa <code>is_valid_permutation(route, n)</code> y <code>validate_population(population, n)</code> .	Se confirma longitud n , conjunto completo y ausencia de repetidos.

La tabla de validacion confirma que todos los datasets terminaron con rutas validas. Ademas, la ejecucion registro cero hijos invalidos, cero hijos reparados y cero generaciones con poblaciones invalidas. Esto es importante porque no basta con encontrar una distancia baja: la solucion debe ser factible para el TSP.

Dataset	n	Ruta final valida	Hijos invalidos	Poblaciones invalidas	Sin repetidas	Sin faltantes
cities_100_101112	85	True	0	0	True	True
cities_100_123	82	True	0	0	True	True
cities_100_131415	88	True	0	0	True	True
cities_100_161718	80	True	0	0	True	True
cities_100_192021	80	True	0	0	True	True
cities_100_222324	82	True	0	0	True	True
cities_100_252627	84	True	0	0	True	True
cities_100_282930	83	True	0	0	True	True
cities_100_456	84	True	0	0	True	True
cities_100_789	80	True	0	0	True	True

Defensa del literal a): La validez no se deja al azar. La representacion, el crossover y la mutacion fueron elegidos para trabajar naturalmente con permutaciones; ademas, el codigo valida cada ruta final y registra si aparecieron soluciones invalidas.

b) Definicion de operadores geneticos y justificacion del uso

El algoritmo principal es un AG generacional elitista. Esto significa que en cada generacion se crea una nueva poblacion de descendientes, pero los mejores individuos de la generacion actual pasan directamente a la siguiente. El elitismo se eligio porque en el TSP una buena ruta puede perderse por azar durante el cruce o la mutacion; conservarla evita retrocesos en la mejor solucion encontrada.

Componente	Como funciona	Justificacion
Seleccion por torneo	Se eligen $k=3$ candidatos al azar y gana el de menor distancia.	Controla la presion selectiva: favorece rutas buenas sin eliminar totalmente la diversidad.
Crossover OX	Se preserva un segmento de un padre y se completa el resto siguiendo el orden del otro padre.	Es valido para permutaciones y conserva informacion de orden, que es clave en el TSP.
Mutacion por inversion	Se seleccionan dos posiciones y se invierte el segmento entre ellas.	Introduce variacion sin crear ciudades repetidas ni faltantes. Ademas, es coherente con la idea de

Proyecto final de IA - TSP mediante Algoritmos Geneticos

		mejorar tramos de una ruta.
Elitismo	Los 2 mejores individuos se copian directamente a la siguiente generacion.	Evita perder la mejor ruta encontrada y mejora la estabilidad de la convergencia.
2-opt final	Se invierten aristas si la inversion reduce la distancia.	Refina localmente la mejor ruta del AG; por eso el enfoque puede defenderse como AG elitista hibrido.

Se eligio OX como operador de crossover porque el TSP depende del orden de visita. Un cruce tradicional de cadenas binarias podria generar rutas con ciudades repetidas o faltantes. OX evita ese problema: primero fija un bloque del padre 1 y luego recorre el padre 2 para insertar solamente las ciudades que todavia no aparecen en el hijo. La mutacion por inversion se eligio porque cambia la geometria de la ruta sin alterar el conjunto de ciudades; por tanto, es mas apropiada para rutas que una mutacion numerica comun.

Defensa del literal b): No se eligio OX en lugar del AG elitista. El AG elitista es la variante principal del algoritmo; OX es el operador de cruce usado dentro de esa variante para asegurar hijos validos en un problema de permutaciones.

c) Analisis de la evolucion del fitness

El fitness se definio como el inverso de la distancia total: $\text{fitness} = 1 / \text{distancia_total}$. Con esta definicion, una ruta mas corta tiene mayor fitness. En cada generacion se registraron tres valores: mejor fitness, fitness promedio y peor fitness. Tambien se guardaron las distancias equivalentes porque son mas faciles de interpretar en terminos del objetivo real del TSP.

Proyecto final de IA - TSP mediante Algoritmos Genéticos

Evolucion del fitness por dataset




Figura 1. Evolucion del mejor fitness, fitness promedio y peor fitness por dataset.

La figura muestra el comportamiento esperado de un AG: el mejor fitness tiende a aumentar y luego estabilizarse; el fitness promedio se acerca gradualmente al mejor fitness conforme la poblacion converge; y el peor fitness puede fluctuar por efecto de la mutacion, pero suele mejorar cuando la poblacion ya ha heredado buenos patrones de ruta.

Proyecto final de IA - TSP mediante Algoritmos Geneticos

Cuando la diferencia entre el mejor y el promedio se reduce demasiado rapido, puede existir riesgo de convergencia prematura, porque muchos individuos se parecen entre si y la exploracion disminuye.

Dataset	Mejor gen.	Gen. sin mejora al final	Unicos final (%)	Hamming final (%)	Diagnostico
cities_100_101112	242	8	35.00	39.00	se observaron mejoras dentro del tramo final del algoritmo.
cities_100_123	230	20	16.00	7.01	se observaron mejoras dentro del tramo final del algoritmo.
cities_100_131415	214	36	19.00	11.02	se observaron mejoras dentro del tramo final del algoritmo.
cities_100_161718	233	17	17.00	6.25	se observaron mejoras dentro del tramo final del algoritmo.
cities_100_192021	225	25	20.00	14.31	se observaron mejoras dentro del tramo final del algoritmo.
cities_100_222324	190	60	16.00	6.71	largo periodo sin mejora y diversidad final baja.
cities_100_252627	170	80	17.00	7.86	largo periodo sin mejora y diversidad final baja.
cities_100_282930	235	15	15.00	7.71	se observaron mejoras dentro del tramo final del algoritmo.
cities_100_456	202	48	18.00	13.30	se observaron mejoras dentro del tramo final del algoritmo.
cities_100_789	237	13	24.00	24.34	se observaron mejoras dentro del tramo final del algoritmo.

El analisis de estancamiento se realizo observando cuantas generaciones finales pasaron sin mejora y si la diversidad final era baja. En 2 de los 10 datasets se identifico posible convergencia prematura, porque hubo un periodo final largo sin mejora junto con baja diversidad. En los demas casos se observo convergencia activa, debido a que todavia existieron mejoras dentro del tramo final.




Figura 2. Comparacion de distancia final entre Nearest Neighbor y AG elitista + 2-opt.

Defensa del literal c): La evolucion del fitness se grafico por generacion para todos los datasets. El criterio de convergencia no se baso solo en mirar la grafica, sino tambien en medir generaciones sin mejora y diversidad final.

d) Medicion y analisis de diversidad poblacional

Se usaron dos metricas de diversidad. La primera fue el porcentaje de individuos unicos en la poblacion. La segunda fue la distancia Hamming promedio normalizada entre pares de individuos, que mide el porcentaje de posiciones en las que dos rutas difieren. Ambas metricas son apropiadas para permutaciones: el porcentaje de unicos detecta duplicacion poblacional y la distancia Hamming permite observar si las rutas tienen ordenamientos parecidos.

Metrica	Calculo	Interpretacion
Porcentaje de individuos unicos	Numero de rutas distintas / tamano de poblacion x 100	Bajo valor indica que muchos cromosomas se repiten.
Distancia Hamming promedio	Promedio del porcentaje de posiciones diferentes entre pares de rutas	Bajo valor indica rutas muy parecidas y posible perdida de exploracion.

Proyecto final de IA - TSP mediante Algoritmos Genéticos

Evolucion de la diversidad por dataset




Figura 3. Evolucion de diversidad poblacional por dataset.

La diversidad disminuye conforme el algoritmo avanza porque la seleccion y el elitismo favorecen la reproduccion de rutas de mejor calidad. Esto es normal y deseable hasta cierto punto: una diversidad muy alta al final puede indicar que la poblacion aun no explota buenas soluciones; pero una diversidad demasiado baja puede indicar convergencia

Proyecto final de IA - TSP mediante Algoritmos Geneticos

prematura. Por eso se analizo la relacion diversidad-calidad y diversidad-convergencia en conjunto, no de manera aislada.

Dataset	Unicos final (%)	Hamming final (%)	Corr. diversidad-distancia	Corr. diversidad-sin mejora
cities_100_101112	35.00	39.00	0.62	-0.23
cities_100_123	16.00	7.01	0.09	-0.26
cities_100_131415	19.00	11.02	0.72	-0.15
cities_100_161718	17.00	6.25	0.70	-0.27
cities_100_192021	20.00	14.31	0.76	-0.43
cities_100_222324	16.00	6.71	0.49	-0.30
cities_100_252627	17.00	7.86	0.43	-0.37
cities_100_282930	15.00	7.71	0.60	-0.23
cities_100_456	18.00	13.30	0.44	-0.35
cities_100_789	24.00	24.34	0.61	-0.29

La correlacion diversidad-distancia se interpreta con cuidado: a medida que baja la diversidad, la distancia suele bajar porque la poblacion converge hacia mejores rutas. Sin embargo, si la diversidad cae demasiado y el numero de generaciones sin mejora aumenta, la convergencia puede volverse prematura. En este proyecto, los datasets cities_100_222324 y cities_100_252627 mostraron el patron mas claro de riesgo: baja diversidad final y muchas generaciones sin mejora.




Figura 4. Diversidad final medida por porcentaje de individuos unicos.

Defensa del literal d): Se midio la diversidad con dos indicadores complementarios. Esto permite explicar no solo si el algoritmo encontro buenas rutas, sino tambien si las encontro manteniendo suficiente exploracion poblacional.

e) Evaluacion de la calidad de las soluciones

La calidad de las soluciones se evaluo comparando el AG con una heuristica simple: Nearest Neighbor. Esta heuristica construye una ruta desde cada ciudad inicial y siempre selecciona como siguiente destino la ciudad no visitada mas cercana. Luego se conserva la mejor ruta obtenida entre todos los puntos de partida. Tambien se calculo Nearest Neighbor + 2-opt para tener una referencia mas fuerte.

Como los datasets no incluyen el optimo teorico certificado, no se puede afirmar error relativo respecto al optimo global. Por transparencia, el error relativo se reporto respecto a las heuristicas de referencia. La formula usada fue:

Proyecto final de IA - TSP mediante Algoritmos Geneticos

gap relativo (%) = ((distancia_AG - distancia_referencia) / distancia_referencia) x 100. Un valor negativo significa que el AG encontro una ruta mas corta que la referencia.

Dataset	n	NN	NN+2opt	AG+2opt	Gap vs NN (%)	Gap vs NN+2opt (%)	Valida
cities_100_101112	85	1619.41	1487.02	1469.42	-9.26	-1.18	True
cities_100_123	82	1676.68	1536.72	1527.83	-8.88	-0.58	True
cities_100_131415	88	1590.97	1472.80	1475.42	-7.26	0.18	True
cities_100_161718	80	1778.42	1586.98	1597.80	-10.16	0.68	True
cities_100_192021	80	1792.02	1564.55	1632.69	-8.89	4.36	True
cities_100_222324	82	1604.02	1493.68	1463.85	-8.74	-2.00	True
cities_100_252627	84	1537.77	1491.85	1461.27	-4.97	-2.05	True
cities_100_282930	83	1551.43	1494.41	1476.72	-4.82	-1.18	True
cities_100_456	84	1644.44	1544.33	1538.99	-6.41	-0.35	True
cities_100_789	80	1591.55	1477.00	1450.54	-8.86	-1.79	True

En promedio, Nearest Neighbor obtuvo una distancia de 1638.67, mientras que AG elitista + 2-opt obtuvo 1509.45. Esto equivale a una mejora promedio de 7.83% frente a la heurística simple. Frente a NN+2-opt, el promedio fue -0.39%; es decir, el AG fue competitivo incluso contra una solución heurística refinada. El caso cities_100_192021 tuvo un gap positivo frente a NN+2-opt, lo que significa que la heurística refinada fue mejor en ese dataset específico; esto es normal en algoritmos aproximados y demuestra por que es importante comparar y no asumir optimalidad.




Figura 5. Gap relativo frente a Nearest Neighbor. Valores negativos representan mejora.

Defensa del literal e): La comparacion se hizo contra una heurística simple, como solicita el literal, y se reporto el error relativo posible. Como no hay optimos certificados, se aclara que el gap no es contra el optimo global sino contra la referencia experimental.

f) Analisis experimental de parametros

El analisis de parametros se realizo sobre el dataset con mas ciudades, cities_100_131415, porque representa el escenario mas exigente de los archivos disponibles. Se evaluaron variaciones en tamano de poblacion, tipo de crossover, probabilidad de crossover y probabilidad de mutacion. Para mantener un costo computacional razonable, el experimento uso 40 generaciones por configuracion y una mejora final 2-opt acotada.

Poblacion	Crossover	Pc	Pm	Distancia	Gap NN (%)	Unicos (%)	Hamming (%)	Valida
100	PMX	0.90	0.20	1455.27	-8.53	24.00	18.24	True
60	OX	0.80	0.20	1455.27	-8.53	21.67	12.05	True
140	OX	0.90	0.20	1455.92	-8.49	25.00	13.75	True
60	PMX	0.80	0.20	1460.41	-8.21	26.67	19.89	True
60	OX	0.80	0.05	1461.26	-8.15	3.33	1.36	True
140	OX	0.90	0.05	1462.68	-8.06	5.00	0.57	True
140	PMX	0.80	0.20	1465.76	-7.87	21.43	4.94	True
100	PMX	0.90	0.05	1465.76	-7.87	7.00	19.09	True
100	OX	0.90	0.20	1467.45	-7.76	21.00	11.70	True
140	OX	0.80	0.20	1468.00	-7.73	21.43	8.64	True




Figura 6. Mejores configuraciones del analisis experimental de parametros.

El resultado no debe interpretarse como una regla universal, sino como evidencia experimental para estos datasets y este presupuesto de generaciones. En esta corrida, OX tuvo menor distancia promedio que PMX, la probabilidad de crossover 0.90 fue mejor que 0.80 y una mutacion de 0.20 mantuvo mejor equilibrio entre exploracion y explotacion que 0.05. El tamano de poblacion mostro un resultado interesante: una poblacion menor no fue necesariamente peor bajo un presupuesto corto de generaciones, porque poblaciones grandes pueden requerir mas generaciones para explotar adecuadamente la diversidad adicional.

Proyecto final de IA - TSP mediante Algoritmos Genéticos




Figura 7. Efecto del tamaño de población en la distancia promedio.




Figura 8. Efecto de la probabilidad de mutación en la distancia promedio.

Proyecto final de IA - TSP mediante Algoritmos Genéticos




Figura 9. Efecto del tipo y probabilidad de crossover.

Parametro	Valores evaluados	Interpretacion
Tamano de poblacion	60, 100 y 140	A mayor poblacion hay mas diversidad potencial, pero tambien puede requerirse mas tiempo para convertirla en mejora.
Tipo de crossover	OX y PMX	OX fue seleccionado como operador base porque preserva orden relativo y mantuvo buen rendimiento promedio.
Probabilidad de crossover	0.80 y 0.90	0.90 favorecio mayor recombinacion de informacion entre padres y mejor resultado promedio en esta prueba.
Probabilidad de mutacion	0.05 y 0.20	0.20 ayudo a sostener diversidad y evitar estancamiento temprano en el experimento.

Defensa del literal f): El analisis de parametros no solo reporta tablas; explica que la calidad del AG depende del equilibrio entre exploracion y explotacion. Por eso se compararon poblacion, crossover y mutacion, que son los factores pedidos en el literal.

Conclusiones tecnicas

- La representacion por permutaciones es la forma correcta de modelar el TSP, porque cada ciudad debe aparecer exactamente una vez en la ruta.
- El AG elitista fue adecuado porque conserva las mejores rutas y evita retrocesos en la mejor solucion encontrada durante la evolucion.
- OX e inversion fueron operadores coherentes con el problema porque generan descendientes validos sin ciudades repetidas ni faltantes.
- El fitness aumento de forma progresiva en la mayoria de los datasets, lo que evidencia convergencia. Dos datasets mostraron posible convergencia prematura, identificada con generaciones sin mejora y baja diversidad.
- El AG elitista + 2-opt fue mejor que Nearest Neighbor en todos los datasets y competitivo frente a NN+2-opt, aunque no se afirma optimalidad global porque no existen optimos certificados en los archivos.
- El analisis de parametros mostro que no existe una configuracion universal; el rendimiento depende del equilibrio entre tamano poblacional, crossover y mutacion.

Resumen de participacion del Grupo 5

Integrante	Responsabilidad asignada	Actividades realizadas
Nancy Altamirano	Preparacion y validacion de datasets	Revision de columnas city, x, y; verificacion de cantidad de ciudades; apoyo en el literal a sobre representacion valida y control de ciudades repetidas/faltantes.
Gustavo Berru	Implementacion del algoritmo genetico	Desarrollo de la estructura del AG elitista, seleccion por torneo, elitismo, funcion fitness, cruce OX y mutacion por inversion; apoyo principal en los literales b y c.
Raquel Pacheco	Evaluacion experimental y comparacion	Ejecucion de la heuristica Nearest Neighbor, calculo de gaps relativos, validacion de resultados finales y analisis de calidad de solucion del literal e.
Kevin Viteri	Graficas, diversidad y documentacion final	Generacion de graficas de fitness y diversidad, analisis de convergencia, experimento de parametros del literal f y consolidacion del informe profesional.

La distribucion anterior reparte las tareas de forma equilibrada y permite defender el proyecto por componentes: datos, algoritmo, evaluacion y comunicacion de resultados.

Referencias de apoyo

- Goldberg, D. E. (1989). Genetic Algorithms in Search, Optimization, and Machine Learning. Addison-Wesley.
- Holland, J. H. (1975). Adaptation in Natural and Artificial Systems. University of Michigan Press.
- Mitchell, M. (1998). An Introduction to Genetic Algorithms. MIT Press.
- Oliver, I. M., Smith, D. J., & Holland, J. R. C. (1987). A study of permutation crossover operators on the traveling salesman problem. Proceedings of the Second International Conference on Genetic Algorithms.
- Croes, G. A. (1958). A method for solving traveling-salesman problems. Operations Research, 6(6), 791-812.

Archivos entregados en el paquete

Archivo/carpeta	Contenido
code/tsp_ga_project.py	Codigo fuente reproducible del AG, heuristica NN, 2-opt, metricas y graficas.
data/*.csv	Datasets originales usados en el proyecto.
results/summary_all_datasets.csv	Resumen cuantitativo de calidad, diversidad, convergencia y validez.
results/validacion_permutaciones.csv	Verificacion de que las rutas no tienen ciudades repetidas ni faltantes.
results/parameter_experiment_largest_dataset.csv	Tabla completa del analisis experimental de parametros.
figures/*.png	Graficas individuales y agregadas de fitness, diversidad, comparacion y parametros.