

# **Taller 2— Algoritmos de Búsqueda y Optimización Bioinspirada**

## **Ensayo**

Maestría en Inteligencia Artificial – USFQ

Oldrin BONILLA

Stan MORA

Tais RODRIGUEZ

# Modelos de lenguaje y algoritmos de búsqueda:

## ¿oposición o convergencia conceptual?

En el campo de la inteligencia artificial, dos grandes enfoques han marcado la evolución en la resolución de problemas: los algoritmos de búsqueda, propios de la IA clásica, y los modelos de lenguaje basados en arquitecturas Transformer, que representan el paradigma dominante en la actualidad (Russell & Norvig, 2021; Vaswani et al., 2017). A primera vista, ambos parecen pertenecer a mundos completamente distintos: uno explora grafos de estados con reglas explícitas; el otro aprende distribuciones de probabilidad sobre millones de textos.

Sin embargo, esta separación superficial oculta una pregunta más profunda, y más interesante: ¿están haciendo algo fundamentalmente diferente, o se trata de dos caras de la misma moneda? Desde la perspectiva de la Ciencia de Datos, responder esta pregunta importa en la práctica: condiciona cómo interpretamos la inferencia de un modelo, cómo elegimos entre soluciones para un problema, y cómo podríamos diseñar sistemas más poderosos combinando lo mejor de cada enfoque. Este ensayo argumenta que, pese a sus diferencias técnicas, los algoritmos de búsqueda y los modelos de lenguaje son conceptualmente convergentes: comparten el esqueleto de explorar un espacio hacia un objetivo, aunque lo hagan de formas radicalmente distintas. La convergencia no es solo teórica; se materializa en técnicas concretas como el *beam search*, y abre la puerta a sistemas híbridos que ya están redefiniendo el estado del arte.

### I. Algoritmos de búsqueda: exploración estructurada y optimización explícita

Los algoritmos de búsqueda representan problemas como grafos dirigidos: los nodos son estados posibles del mundo, las aristas son acciones o transiciones, y la meta es encontrar un camino óptimo desde un estado inicial hasta uno objetivo, según una función de costo bien definida (Russell & Norvig, 2021). Esta representación tiene una virtud fundamental: *todo es transparente*. Sabemos exactamente qué se está explorando, por qué se elige un camino y cuándo se ha llegado a la solución. El algoritmo BFS (*Breadth-First Search*) garantiza encontrar el

camino más corto en grafos no ponderados, explorando todos los vecinos antes de avanzar un nivel. Sin embargo, su consumo de memoria crece exponencialmente con la profundidad del grafo.

El algoritmo A\* (Hart, Nilsson & Raphael, 1968) resolvió en gran medida este problema introduciendo una función heurística  $h(n)$  que guía la búsqueda hacia regiones más prometedoras del espacio de estados, reduciendo dramáticamente el número de nodos que es necesario explorar. Siempre que la heurística sea *admisible* (es decir, nunca sobreestime el costo real), A\* garantiza encontrar la solución óptima.

Desde la perspectiva de la Ciencia de Datos, los algoritmos de búsqueda clásicos son procesos de optimización discreta y determinista, con tres propiedades que los hacen especialmente valiosos en ciertos contextos: la función objetivo es explícita y auditable, la evaluación de cada estado es determinista, y el proceso completo es interpretable paso a paso. Esta interpretabilidad no es un lujo académico: en aplicaciones críticas como planificación médica, navegación autónoma o juegos de estrategia, poder explicar por qué el sistema tomó una decisión es tan importante como la decisión misma.

La limitación estructural de estos algoritmos es el crecimiento exponencial del espacio de búsqueda. En el ajedrez, por ejemplo, el número de posiciones posibles supera el número de átomos en el universo observable. Incluso con heurísticas excelentes, la búsqueda exhaustiva se vuelve inviable para dominios de alta dimensionalidad o con reglas imprecisas, como el lenguaje natural. Fue precisamente esta limitación la que motivó el surgimiento de un enfoque radicalmente distinto.

## **II. Modelos de lenguaje: aprendizaje probabilístico e inferencia en espacios latentes**

Los modelos de lenguaje basados en la arquitectura Transformer (Vaswani et al., 2017) operan sobre un principio completamente diferente. En lugar de definir un espacio de estados explícito y navegarlo, aprenden una función paramétrica que captura la distribución de probabilidad del lenguaje directamente desde los datos:

$$P(x_t \mid x_1, x_2, \dots, x_{t-1})$$

Esta función se aprende minimizando la entropía cruzada entre las predicciones del modelo y el texto real, usando variantes de *gradient descent* sobre conjuntos de datos de escala masiva (Goodfellow, Bengio & Courville, 2016). El resultado es un modelo con miles de millones de parámetros que ha internalizado, de forma implícita, enormes cantidades de conocimiento sobre gramática, hechos del mundo, razonamiento y estilo.

El mecanismo central que hace posible esto es la atención multi-cabeza (*multi-head self-attention*), que permite al modelo ponderar dinámicamente qué partes del contexto previo son relevantes para predecir el siguiente token. A diferencia de las redes recurrentes anteriores, Transformer procesa toda la secuencia en paralelo, lo que permite escalar el entrenamiento a corpus de billones de palabras (Brown et al., 2020). Modelos como GPT-3 y sus sucesores demostraron que esta escala genera capacidades emergentes que no estaban explícitamente programadas: razonamiento aritmético, traducción, programación y síntesis de argumentos.

Durante la inferencia, el modelo genera texto de forma autoregresiva: produce un token a la vez, condicionando cada predicción en todos los tokens anteriores. La estrategia de decodificación determina qué token se selecciona en cada paso: *greedy decoding* toma siempre el token más probable; *sampling* muestrea de la distribución completa para generar variedad; y *beam search* mantiene un conjunto de las k secuencias más prometedoras en paralelo (Devlin et al., 2019). Esta última estrategia es, como veremos, el puente conceptual más importante entre los dos enfoques.

Desde la Ciencia de Datos, los LLM implican trabajar en espacios de alta dimensión donde no existe una función objetivo auditable en tiempo de inferencia, ni garantías formales de optimalidad. La fortaleza está en otro lugar: una capacidad de generalización que ningún sistema de búsqueda clásico puede igualar, y la habilidad de manejar la ambigüedad y el contexto abierto que caracterizan al lenguaje humano.

### **III. Convergencia: hacia una interpretación como búsqueda probabilística**

A pesar de sus diferencias, es posible —y útil— establecer una convergencia conceptual entre ambos paradigmas. El *beam search* es el caso más ilustrativo: cuando un modelo de lenguaje genera texto usando esta estrategia, está literalmente realizando una búsqueda en árbol sobre el espacio de secuencias posibles, manteniendo las  $k$  hipótesis más probables en cada paso y expandiéndolas en paralelo. La diferencia con  $A^*$  no es de naturaleza, sino de representación: en lugar de una función de costo definida por reglas, se usa la log-probabilidad acumulada como función objetivo.

Esta analogía permite reformular los LLM en términos que los algoritmos de búsqueda reconocerían:

- Espacio de estados: el conjunto de todas las secuencias de tokens posibles.
- Función objetivo: la probabilidad conjunta aprendida durante el entrenamiento.
- Estrategia de exploración: greedy, sampling o beam search.
- Solución: la secuencia generada que maximiza (aproximadamente) esa función.

Sin embargo, esta búsqueda tiene limitaciones importantes que la diferencian del ideal clásico. No es exhaustiva: el espacio de secuencias crece exponencialmente con la longitud, por lo que ninguna estrategia de decodificación realista puede explorar más que una fracción ínfima de él. Tampoco garantiza optimalidad: incluso con beam search, la secuencia encontrada puede no ser la de mayor probabilidad global (Stahlberg & Byrne, 2019). En ese sentido, los LLM implementan una *búsqueda heurística implícita* en un espacio probabilístico aprendido.

Esta convergencia conceptual no es solo un ejercicio intelectual: tiene implicaciones prácticas directas para la Ciencia de Datos. Comprender que la generación de texto es una forma de búsqueda ayuda a diagnosticar fallos del modelo (por ejemplo, la tendencia al texto repetitivo con greedy decoding), a elegir la estrategia de decodificación apropiada para cada tarea, y a diseñar sistemas más robustos que combinen la estructura explícita de la búsqueda con la flexibilidad del aprendizaje. Desarrollos recientes como *AlphaCode* y los modelos de razonamiento con cadena de pensamiento (*chain-of-thought*) son evidencia de esta dirección: integran planificación explícita dentro de la generación probabilística (Wei et al., 2022).

## Conclusión

Los algoritmos de búsqueda y los modelos de lenguaje representan dos filosofías distintas pero complementarias dentro de la inteligencia artificial. Los primeros destacan por su rigor, interpretabilidad y garantías formales: sabemos exactamente qué buscan y por qué llegan a una solución. Los segundos destacan por su capacidad de aprendizaje, generalización y manejo de la complejidad abierta del lenguaje natural.

Desde la Ciencia de Datos, los modelos de lenguaje pueden entenderse como sistemas de búsqueda probabilística implícita: en lugar de navegar un grafo predefinido, navegan un espacio de distribuciones aprendidas desde los datos, usando estrategias de decodificación que son, en esencia, algoritmos de búsqueda adaptados. Esta lectura no disuelve las diferencias reales entre ambos paradigmas, pero sí revela la unidad profunda que las subyace.

El futuro inmediato de la IA apunta hacia sistemas híbridos que integren la precisión de la búsqueda estructurada con la flexibilidad del aprendizaje automático. Arquitecturas como AlphaGo —que combina redes neuronales profundas con Monte Carlo Tree Search— o los modelos de razonamiento con planificación explícita son precursores de esta convergencia (Silver et al., 2017). Para un científico de datos, entender ambos paradigmas y sus puentes no es solo un ejercicio académico: es una ventaja competitiva real a la hora de diseñar, evaluar y mejorar sistemas de inteligencia artificial.

## Bibliografía

[1] Brown, T., Mann, B., Ryder, N., et al. (2020). *Language Models are Few-Shot Learners*. Advances in Neural Information Processing Systems (NeurIPS), 33, 1877–1901.  
<https://arxiv.org/abs/2005.14165>

[2] Devlin, J., Chang, M.-W., Lee, K., & Toutanova, K. (2019). *BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding*. Proceedings of NAACL-HLT 2019, 4171–4186.  
<https://arxiv.org/abs/1810.04805>

[3] Goodfellow, I., Bengio, Y., & Courville, A. (2016). *Deep Learning*. MIT Press.  
<https://www.deeplearningbook.org>

[4] Hart, P. E., Nilsson, N. J., & Raphael, B. (1968). *A formal basis for the heuristic determination of minimum cost paths*. IEEE Transactions on Systems Science and Cybernetics, 4(2), 100–107.  
<https://doi.org/10.1109/TSSC.1968.300136>

- [5] Russell, S., & Norvig, P. (2021). Artificial Intelligence: A Modern Approach (4th ed.). Pearson.  
<https://aima.cs.berkeley.edu>
- [6] Silver, D., Schrittwieser, J., Simonyan, K., et al. (2017). *Mastering the game of Go without human knowledge*. Nature, 550, 354–359.  
<https://doi.org/10.1038/nature24270>
- [7] Stahlberg, F., & Byrne, B. (2019). On NMT Search Errors and Model Errors: Cat Got Your Tongue? Proceedings of EMNLP-IJCNLP 2019, 3356–3362.  
<https://arxiv.org/abs/1908.10090>
- [8] Vaswani, A., Shazeer, N., Parmar, N., et al. (2017). *Attention Is All You Need*. Advances in Neural Information Processing Systems (NeurIPS), 30.  
<https://arxiv.org/abs/1706.03762>
- [9] Wei, J., Wang, X., Schuurmans, D., et al. (2022). *Chain-of-Thought Prompting Elicits Reasoning in Large Language Models*. Advances in Neural Information Processing Systems (NeurIPS), 35.  
<https://arxiv.org/abs/2201.11903>